TECNOLOGIE DEL LINGUAGGIO NATURALE - RADICIONI

RELAZIONE ESERCITAZIONE 1

Roger Ferrod, Simone Cullino, Davide Giosa

SOMMARIO

La seguente esercitazione richiede di calcolare, tramite WordNet, la similarità massima tra coppie di termini e confrontarla, tramite indici di correlazione, con un gold value annotato manualmente. Per il calcolo della similarità sono state utilizzate tre metriche: Wu & Palmer, Shortest Path e Leakcock & Chodorow. Mentre gli indici di correlazione presi in considerazione sono Pearson e Spearman.

IMPLEMENTAZIONE

Per lo svolgimento di questa esercitazione abbiamo diviso il codice in 4 moduli:

- WordNetDriver.py contiene i metodi che si interfacciano a WordNet
- Metrics.py contiene l'implementazione delle tre metriche: Wu & Palmer, Shortest Path e Leakcock & Chodorow
- Indeces.py contiene l'implementazione degli indici di correlazione: Pearson e Spearman
- Es1.py punto di avvio dell'esercitazione, chiama iterativamente i vari metodi utilizzando tutte le metriche e gli indici fortini dagli appositi moduli.

RISULTATI

L'output dell'esercitazione consiste in due file: il primo file contiene, per ogni coppia di termini, le tre concept-similarity calcolate e il golden-value; il secondo file contiene invece i due indici di correlazione calcolati per ogni metrica.

Abbiamo deciso inoltre di fornire un grafico per ogni metrica contenente sull'asse delle ascisse il golden-value e sull'asse delle ordinate la similarità calcolata. In tal modo è possibile verificare visivamente l'allineamento dei dati e confrontarli con i coefficienti di correlazione calcolati. I risultati sono riportati di seguito:

- Wu & Palmer:
 - Pearson: 0.299Spearman: 0.060
- Shortest Path:

Pearson: 0.207Spearman: 0.016

• Leakcock & Chodorow:

Pearson: 0.331Spearman: 0.016